ChatGPT

Analyse de marché et optimisation algorithmique d’un système de scoring social pour les musiques électroniques

Résumé exécutif

Au 23 septembre 2026, la musique électronique constitue à la fois un marché mondial important, un ensemble de scènes locales extrêmement fragmentées et un terrain particulièrement adapté aux systèmes de recommandation. L’International Music Summit estime la valeur de l’écosystème électronique mondial à **15,1 Md$ en 2025, en hausse de 7 %**, en incluant plusieurs composantes au-delà de la seule musique enregistrée : publishing, revenus des plateformes numériques, live, merchandising et autres revenus de fandom. L’IMS indique également que l’électronique a gagné environ **0,6 milliard de “fans” additionnels agrégés** sur Spotify, YouTube, TikTok, Instagram et Facebook en 2025, que l’Allemagne demeure le principal marché électronique mesuré par son approche, et que le genre figure parmi les trois premiers dans presque tous ses grands marchés. [1]

Ce chiffre de 15,1 Md$ ne doit **pas** être comparé directement à la taille de la seule musique enregistrée : l’IFPI chiffre cette dernière à **31,7 Md$ mondialement en 2025**, dont 69,6 % proviennent du streaming et 52,4 % du streaming par abonnement. L’électronique est ici un écosystème transversal comprenant notamment le live, les logiciels/outils et le direct-to-fan, alors que l’IFPI mesure la musique enregistrée. [2]

Pour un produit comme Kinda, le point stratégique essentiel est que la découverte musicale n’est plus un funnel linéaire « média → écoute ». Elle circule entre vidéos courtes, DJ sets, clubs et festivals, playlists algorithmiques, communautés SoundCloud/Bandcamp, curateurs, artistes, labels et groupes sociaux. En France, tous genres confondus, **47 % des auditeurs de musique utilisent réseaux sociaux ou vidéos courtes pour écouter de la musique** ; 71 % de ceux qui découvrent un morceau via une vidéo courte le réécoutent ensuite en streaming. Chez les 15–24 ans, 94 % utilisent le streaming et 41 % placent les vidéos courtes dans leur parcours de découverte. [3] TikTok rapporte de son côté plus de **6 milliards d’ajouts de titres vers des services de streaming premium sur les douze mois précédant avril 2026**, ce qui illustre directement la transformation de découverte sociale en intention d’écoute. [4]

La musique électronique renforce encore cette logique. SoundCloud indique qu’elle est son genre à la croissance la plus rapide sur les trois dernières années et que la part des uploads électroniques est passée d’environ **un quart des titres en 2020 à plus d’un tiers en 2025**. [5] Beatport, qui dessert plus de 80 000 labels et 400 000 artistes, montre parallèlement une taxonomie professionnelle beaucoup plus fine que les grandes catégories généralistes ; Tech House reste son genre le plus vendu tandis qu’Afro House fait partie des poches de forte croissance identifiées par l’IMS. [6]

L’actuel système Kinda part de bonnes fondations. Il déduplique avant tout appel coûteux, maintient trois notes indépendantes — `relevance`, `emergence`, `hotness` —, utilise un préfiltre local fail-open, protège les artistes suivis et les événements multi-sources, applique des garde-fous déterministes aux

posts Instagram quasi vides et conserve séparément la mémoire A&R. Cette séparation des objectifs est précisément ce qu'il ne faut pas casser. Sur les 455 contenus scorés au 23 septembre 2026, 56 % ont une pertinence inférieure à 40, 24 % sont entre 60 et 79 et 2 % dépassent 80 ; `other` représente toutefois 186 contenus, soit environ 41 % des 455 scorés, et aucune occurrence `ecology` n'est observée. Le préfiltre local n'a évité que 31 appels sur 455 scores, soit environ 7 %. filecite turn0file0

La principale faiblesse n'est donc pas le prompt. **Kinda utilise aujourd'hui surtout un jugement éditorial sémantique alors qu'un véritable feed de recommandation doit combiner quatre familles de connaissance : contenu, utilisateur, graphe et comportement.** Le système ne doit pas remplacer `relevance/emergence/hotness` par une note universelle. Il doit ajouter au-dessus d'elles un quatrième objet : un `rank_score(user, post, context)`, calculé uniquement après les règles d'éligibilité.

L'architecture recommandée est une recommandation hybride multi-étages inspirée des systèmes industriels publiquement documentés par Spotify, YouTube, TikTok et SoundCloud : récupération de candidats par plusieurs moteurs, ranking personnalisé, puis reranking de diversité. YouTube a historiquement formalisé l'architecture « candidate generation → ranking » à grande échelle. [7] Spotify combine aujourd'hui représentations collaboratives et audio, plusieurs horizons temporels, mises à jour batch et quasi temps réel et mécanismes explicites d'exploration du nouveau contenu. [8] SoundCloud combine proximité audio, interactions sociales et exposition initiale contrôlée des nouveaux uploads à des auditeurs compatibles. [9]

La formule initiale proposée pour le feed personnalisé est :

$$B(u,p,t) = 0{,}22P + 0{,}20E + 0{,}12V + 0{,}10Q + 0{,}09F + 0{,}08G + 0{,}07A + 0{,}05N + 0{,}04L + 0{,}03X$$

$$Score(u,p,t) = 100 \times C \times \mathrm{clip}(B(u,p,t) - 0{,}35R,\ 0,\ 1)$$

où `P` est l'affinité personnalisée, `E` la pertinence éditoriale calibrée, `V` la vélocité d'engagement corrigée de l'exposition, `Q` la qualité/information, `F` la fraîcheur, `G` le graphe social/artistique, `A` l'affinité audio, `N` la nouveauté, `L` la pertinence locale, `X` l'exploration et `R` le risque d'abus ; `C` est une porte d'éligibilité/sécurité. Ces valeurs sont des **priors de démarrage**, pas des poids supposés optimaux : ils doivent être appris et recalibrés sur les logs Kinda.

La recommandation la plus importante est de conserver des **portes non compensables** : un utilisateur amateur de techno ne doit pas transformer un post techno sans information en actualité éditoriale de qualité. Le flux principal garde donc par défaut `relevance ≥ 60` ; la voie A&R peut prendre `emergence ≥ 55` indépendamment de cette condition ; l'alerte chaude doit conserver `hotness ≥ 80` **et** exiger une pertinence suffisante. Ce principe prolonge directement l'architecture actuelle de Kinda. filecite turn0file0

Enfin, il ne faut pas surdimensionner la première version. Avec quelques centaines d'articles actuellement en base, un système Kafka + deep-learning temps réel généralisé constituerait de l'over-engineering. **Le meilleur prochain modèle est probablement un ranker LightGBM/LambdaMART ou équivalent, alimenté par embeddings de texte/audio, statistiques d'engagement corrigées, graph features légères et règles éditoriales**, servi sur PostgreSQL/pgvector + Redis. Le two-tower, le GNN et les contextual bandits deviennent pertinents lorsque Kinda dispose de suffisamment d'interactions utilisateurs et d'un trafic permettant des expérimentations significatives.

La séquence prioritaire est donc : **instrumenter → annoter → calibrer → ajouter engagement corrigé → ajouter embeddings → personnaliser → diversifier → explorer**. Les couches plus sophistiquées viennent ensuite.

Marché, définition et écosystème

La « musique électronique » ne correspond pas à un seul marché culturel homogène. Historiquement, elle englobe aussi bien la création électroacoustique et expérimentale que les musiques de danse construites autour du studio, du DJing, du sampling, des synthétiseurs et du club. En France, l'INA rattache l'un de ses principaux lignages à Pierre Schaeffer et aux recherches qui commencent en 1948 avant la constitution du GRM ; l'INA-GRM reste aujourd'hui un acteur de création, recherche et édition électroacoustique. [10] La taxonomie commerciale moderne est beaucoup plus ramifiée : Beatport distingue aujourd'hui notamment House, Tech House, Techno, Drum & Bass, Trance, Progressive House, Afro House, Amapiano, Ambient/Experimental, Bass/Club, Hard Dance, genres globaux et de nombreuses sous-familles. [11]

Cette largeur historique est importante algorithmiquement : **« electronic » doit être une famille multi-label, jamais un tag binaire**. Un live ambient de 50 minutes, un reel hard techno à 155 BPM, une sortie Afro House, un EP IDM expérimental et un set UK garage peuvent tous appartenir à l'électronique tout en ayant des comportements de consommation, des cycles de fraîcheur et des communautés radicalement différents.

Taille et dynamique du marché. L'IMS estime l'économie électronique à 15,1 Md$ en 2025, +7 %, avec croissance répartie entre plusieurs sources de revenus ; publishing, revenus DSP et merchandising font partie des composantes les plus dynamiques. L'électronique reste très mondialisée : l'Allemagne conserve la première place du marché dans les métriques IMS et l'audience des principaux territoires mesurés a progressé de 11 %. Tech House reste en tête des ventes Beatport, tandis qu'Afro House est cité comme une zone particulièrement dynamique. [1]

Il faut éviter de tirer de ces chiffres une fausse précision par sous-genre. Les sources publiques récentes ne fournissent pas de ventilation globale cohérente du chiffre d'affaires de l'électronique entre techno, house, D&B, ambient, bass, EDM, etc. Il est donc plus rigoureux d'utiliser **des indices de demande différents selon les canaux** : ventes Beatport pour les DJs, uploads et streams SoundCloud pour les scènes émergentes, comportements streaming pour le grand public, données de live pour les territoires et recherches/producteur pour les signaux de création.

Macro-segment	Caractéristiques de consommation	Signaux particulièrement utiles au scoring	Situation récente observable
House / Tech House	Clubs, festivals, Beatport, playlists, sets DJ	BPM, label, DJ support, Beatport, playlist velocity, club/event graph	Tech House reste le genre Beatport le plus vendu selon IMS 2026. [1]

Macro-segment	Caractéristiques de consommation	Signaux particulièrement utiles au scoring	Situation récente observable
Techno / hard techno / hardcore	Fort poids live, UGC de clubs, DJ sets, micro-scènes	BPM, énergie, lieu, promoteur, UGC, géographie, repost graph	Les données SoundCloud montrent une poussée de scènes électroniques plus rapides et une forte croissance globale de l'électronique. [5]
Drum & Bass / bass / UKG	Sets, communautés spécialisées, clips courts, SoundCloud	sous-genre, tempo, remix/repost, artiste/label graph	La taxonomie Beatport maintient ces familles comme catégories professionnelles distinctes. [11]
Afro House / Amapiano / global club	Forte dimension transnationale, danse, short-form, DJ sets	géographie, audio embedding, rythme, créateurs, trend cross-market	Afro House est l'un des segments de croissance mis en avant par IMS. [1]
Trance / progressive / melodic	Playlists, festivals, catalogues longs, fans fidélisés	artiste/label affinity, audio similarity, catalogue	Les taxonomies professionnelles les distinguent encore nettement, ce qui plaide contre un unique tag « EDM ». [11]
Ambient / experimental / electroacoustique	Écoute longue, Bandcamp, blogs, radio, labels de niche	dwell long, éditorial, label, timbre, text/ audio embeddings	Beatport a récemment renforcé Ambient/Experimental comme catégorie distincte ; le lignage électroacoustique français reste institutionnellement actif via l'INA-GRM. [12]
EDM / dance-pop / mainstage	DSP, festivals, YouTube, TikTok, Instagram	popularité, completion vidéo, social velocity, événement, artiste	L'électronique est devenue un genre global de premier rang sur de nombreux marchés IMS. [1]

Géographies. La carte la plus pertinente pour Kinda comporte au moins trois étages. Le premier est celui des marchés matures de scène et d'infrastructure — Allemagne, France, Royaume-Uni, Pays-Bas, Espagne, États-Unis, Australie. Le deuxième est celui des marchés à forte croissance numérique ; l'IMS souligne notamment le déplacement de la croissance générale du streaming vers le Global South et la croissance des principaux territoires électroniques. [1] Le troisième est **hyperlocal** : villes, clubs, collectifs, festivals et bassins de scènes. Les travaux de Spotify sur la musique locale montrent que la notion de « local » peut être identifiée statistiquement par une audience anormalement concentrée dans une zone et que des recommandations locales ont produit un engagement significativement supérieur aux contrôles, particulièrement chez les plus jeunes participants. [13]

C'est particulièrement pertinent pour la France. Le marché français de musique enregistrée a atteint environ **1,071 Md€ en 2025, +3,9 %**, avec 702 M€ de streaming ; les abonnements payants représentent 553 M€.

[14] Le live français est lui aussi massif : en 2024, le CNM comptabilise 69 663 représentations payantes, 37,9 millions d'entrées et **1,6 Md€ HT de billetterie**, même si l'année est partiellement amplifiée par les Jeux olympiques et paralympiques. Les festivals seuls représentent 313 M€ HT mais ont vu leur fréquentation reculer de 5 %. [15]

Pour Kinda, « France » ne devrait donc pas être une simple variable `is_french`. Il faut modéliser au minimum **pays → région → ville → lieu → événement**, avec proximité douce. La priorité Bretagne déjà inscrite dans l'actuel système est une bonne règle éditoriale, mais elle gagnerait à devenir une feature explicite plutôt qu'une consigne cachée dans le prompt. filecite turn0file0

Démographie. Les données publiques ne permettent pas de déclarer sérieusement qu'il existe un « auditeur électronique moyen » mondial : techno, EDM, ambient et bass n'ont pas la même population. Les données françaises tous genres sont cependant très instructives sur les comportements des jeunes : 94 % des 15–24 ans utilisent le streaming, 52 % les jeux vidéo et 41 % les vidéos courtes pour la découverte. [3] La bonne stratégie est donc de ne pas encoder « jeunesse = électronique », mais de modéliser séparément âge du compte, historique d'écoute, format préféré, scène et contexte — en évitant les caractéristiques personnelles sensibles.

Les canaux ne remplissent pas le même rôle.

Canal	Rôle dominant dans le funnel	Signal à intégrer dans Kinda	Modèle économique / valeur
Spotify et autres DSP	écoute longue, répétition, playlists, abonnement	artistes suivis, co-consommation, saves, skips, embeddings	abonnement + publicité ; le streaming représente 69,6 % du revenu mondial de la musique enregistrée 2025. [2]
TikTok	découverte, mémétique, danse, UGC, trends	completion, rewatch, partage, sound ID, vitesse	publicité, commerce, transfert vers DSP ; >6 Md de sauvegardes vers DSP via Add to Music App en 12 mois. [4]
Instagram / Reels	identité, artiste-fan, UGC live, partage entre amis	watch/skip, DM/share, social graph, localité, creator affinity	publicité et creator ecosystem ; Instagram a renforcé en 2025–26 recommandations sociales, Blends et contrôle thématique de Reels. [16]
SoundCloud	émergence, remixes, DJ/producer culture, long tail	audio embedding, repost, follow, like graph, premiers fans	abonnement/fan-powered ecosystem ; l'électronique y représente désormais plus d'un tiers des uploads 2025. [5]
Bandcamp	achat direct, niches, collection, profondeur éditoriale	achat, wishlist, collection, label, curator/editorial	15 % sur numérique, 10 % merch ; environ 82 % en moyenne revient à l'artiste selon Bandcamp. [17]

Canal	Rôle dominant dans le funnel	Signal à intégrer dans Kinda	Modèle économique / valeur
Beatport	outil professionnel des DJs, découverte orientée mix	charts genre, label, release, BPM/key, DJ context	téléchargements, streaming/outils DJ ; >80 000 labels et 400 000 artistes supportés. [18]
Clubs, festivals, DJ sets	validation culturelle, communauté, expérience	booking, slot, venue reputation, lineup graph, UGC local	billets, VIP, sponsoring, bar, merchandising ; le live reste central dans l'économie électronique. [1]
Radio / blogs / podcasts	contexte, crédibilité, narration, niche	source expertise, article depth, curator identity	publicité, sponsoring, abonnement, influence indirecte ; le CNM mesure radio, vidéo et streaming comme couches distinctes de diversité musicale. [19]
Bandcamp Daily / curateurs / communautés	découverte humaine longue traîne	curator graph, collection co-occurrence	direct-to-fan et conversion vers achats ; Bandcamp combine éditorial, radio et playlists de fans. [20]

L'un des changements les plus importants du paysage est ainsi la multiplication des **gatekeepers** plutôt que leur disparition. Le label, le booker, le promoteur, le DJ résident, le programmateur de festival et le journaliste restent importants, mais ils sont désormais superposés à des gatekeepers algorithmiques — playlists, systèmes « For You », search ranking — et communautaires — curateurs, reposteurs, amis, Discords, collectifs, fan collections.

Pour Kinda, cette structure doit devenir un **graphe de crédibilité musicale** :

`Artiste ↔ Label ↔ Release ↔ DJ ↔ Club ↔ Promoteur ↔ Festival ↔ Média ↔ Curateur ↔ Utilisateur`

La valeur d'un signal dépend alors de la relation et non de la seule popularité. Un repost d'un DJ respecté dans une micro-scène peut être plus informatif pour l'`emergence` qu'un million de vues génériques ; une première programmation dans un club reconnu peut être plus prédictive qu'un grand nombre de followers ; et un article de fond spécialisé peut avoir une faible `hotness` mais une forte valeur culturelle.

Tendances d'usage et implications pour le produit

La vidéo courte est devenue une couche de distribution musicale, pas seulement un canal marketing. Le baromètre du CNM montre que les vidéos courtes produisent un fort transfert vers l'écoute longue : 71 % des utilisateurs concernés réécoutent en streaming une musique découverte par cette voie. [3] TikTok a matérialisé ce lien dans le produit en connectant découverte et bibliothèques DSP ; son compteur de 6

milliards de sauvegardes sur douze mois rend le signal `save_to_music` particulièrement intéressant comme proxy de valeur musicale, bien plus qu'un simple like. [4]

Cela plaide pour une hiérarchie d'engagement dans Kinda. Un like doit être considéré comme bon marché. Un partage privé, une sauvegarde, un follow d'artiste, l'ouverture du titre complet ou le clic vers un événement doivent peser davantage. La durée de visionnage elle-même doit être corrigée de la durée du contenu : regarder 19 secondes sur un reel de 20 secondes n'équivaut pas à 19 secondes sur un DJ set de 90 minutes.

TikTok confirme publiquement cette logique multidimensionnelle : son feed apprend notamment des likes, partages, favoris, commentaires, durée de visionnage, complétion, abonnements et recherches ; il incorpore également récence, durée, son utilisé et proximité locale, tout en évitant certaines répétitions et en appliquant des contrôles supplémentaires aux contenus en forte croissance. [21]

La recommandation algorithmique devient elle-même un média. Spotify explique que ses différents produits ont des objectifs distincts : Discover Weekly vise davantage la découverte, alors que Daily Mix exploite davantage les préférences déjà établies. Pour résoudre le cold-start créateur, Spotify a construit une couche d'exploration centralisée et rapporte qu'un test en production a multiplié par dix le nombre d'auditeurs du contenu exploré sans dégrader les métriques locales du système concerné. [22]

Le parallèle avec Kinda est direct : la logique A&R ne devrait pas essayer de « gagner » contre les actualités mainstream dans un classement unique. Elle devrait disposer d'un **budget d'exploration explicite**.

Les systèmes deviennent multimodaux et multi-échelles temporelles. Spotify décrit une représentation utilisateur combinant embeddings audio, signaux collaboratifs et interactions agrégées sur environ six mois, un mois et une semaine. La représentation est actualisée en batch pour la couverture et en quasi temps réel, en quelques minutes après des interactions pertinentes, pour refléter les changements de goût. Les ablations publiées indiquent que retirer les encodeurs audio+collaboratifs ou les signaux d'onboarding dégrade significativement différentes métriques de recommandation. [23]

Pour l'électronique, c'est encore plus important qu'en musique généraliste : un utilisateur peut avoir un « goût structurel » pour la techno mais traverser pendant deux semaines une phase trance, Afro House ou drum & bass. Il faut donc distinguer :

$$Taste_u = w_L Taste_{6m} + w_M Taste_{30j} + w_S Taste_{7j} + w_{session} Intent_{session}$$

Un bon démarrage serait `0,35 / 0,25 / 0,25 / 0,15`, à réapprendre ensuite.

Le social revient au cœur de la recommandation. SoundCloud sélectionne ses related tracks à partir d'un réseau d'interactions comprenant likes, follows et reposts. [24] Son rapport 2026 indique également que l'utilisation de playlists sociales de type « Liked By » accroît fortement la probabilité d'explorer hors de son genre dominant et d'interagir avec les titres découverts. [25] Instagram a, de son côté, généralisé un onglet Friends dans Reels et les feeds Blend, qui injectent explicitement dans la découverte ce que regardent ou apprécient les relations sociales. [26]

Il faut donc éviter une architecture où « follower_count » résume le social. Les signaux plus utiles sont la **proximité entre goûts**, la nature de la relation, le taux historique de conversion d'un curateur vers une découverte durable et la structure du graphe.

La communauté humaine devient un différenciateur face à l'hyper-personnalisation. Bandcamp associe marketplace, éditorial Bandcamp Daily, radio, collections et playlists sélectionnées par les fans ; les fans y ont versé environ 1,8 Md$ aux artistes cumulativement selon la plateforme. [27] Les Bandcamp Fridays ont en outre transféré plus de 150 M$ vers les musiciens indépendants sur leurs cinq premières années. [28]

Pour Kinda, cela suggère qu'une bonne expérience ne devrait pas être un unique « For You ». Trois surfaces complémentaires seraient plus robustes :

Surface	Objectif	Optimisation principale
Pour vous	pertinence personnalisée	affinité + qualité + fraîcheur
Ce qui monte	découverte de scènes/artistes	emergence + accélération + exploration
La sélection Kinda	identité éditoriale	relevance éditoriale + diversité + choix humain

Cette séparation réduit le risque qu'un modèle uniquement orienté engagement dissolve progressivement la ligne éditoriale.

L'IA générative change à la fois l'offre et le problème de confiance. L'IMS décrit l'IA comme une technologie appelée à modifier création, travail et consommation dans l'électronique. [1] En France, l'étude CNM/BearingPoint 2025, fondée sur recherche documentaire et une trentaine d'entretiens professionnels, conclut à des opportunités réelles mais à la nécessité d'une intégration contrôlée. [29] SoundCloud utilise déjà l'IA pour l'analyse sonore, le tagging et la découverte en cherchant à faire émerger des titres sur leurs caractéristiques audio plutôt que sur leur popularité initiale. [30]

La conséquence algorithmique est double. L'IA facilite le **cold-start audio**, mais elle rend plus important le contrôle de provenance, de duplication, de spam industriel et d'authenticité des interactions. Une plateforme ne doit pas automatiquement pénaliser la musique générée ou assistée par IA si cela n'est pas sa politique ; elle doit en revanche empêcher qu'une production massive à bas coût capture mécaniquement les budgets d'exposition.

Le live reste le mécanisme de validation irremplaçable de l'électronique. L'IMS continue de placer clubs et live au cœur de l'écosystème, tandis que le CNM mesure une économie live française de 1,6 Md€ HT de billetterie en 2024. [31] Pour un algorithme Kinda, un booking crédible, un set viral correctement identifié ou plusieurs UGC indépendants d'un même show ne devraient donc pas être traités comme de simples « posts Instagram ».

C'est justement l'une des bonnes décisions du système actuel : les vidéos smartphone brutes d'un concert, club ou festival peuvent obtenir une pertinence de 60 à 80 lorsque l'artiste ou l'événement est notable et que l'engagement décolle, même si la légende est faible. filecite turn0file0 L'étape suivante consiste à détecter cette valeur **multimodalement**, plutôt que par prompt uniquement : artiste reconnu dans l'audio/vidéo, lieu, heure, cluster UGC, augmentation des reposts et reconnaissance audio.

Benchmark algorithmique et enseignements

Les plateformes ne publient évidemment pas leur fonction de ranking complète. Le tableau suivant compare donc uniquement ce qui est publiquement documenté par les entreprises ou leurs équipes de recherche, et non une reconstruction supposée de leurs secrets industriels.

Système	Signaux publiquement documentés	Architecture / mécanisme	Cold-start et exploration	Diversité, sécurité, anti-gaming	Leçon pour Kinda
Spotify	historique, séquences, contexte, audio, co-occurrence collaborative, onboarding, pays, horizons temporels	embeddings utilisateur/item, ANN, retrieval + ranking, exploration centralisée, contextual bandits	exploration dédiée nouveaux contenus ; onboarding et embeddings multimodaux	objectifs distincts selon surfaces ; travaux sur diversité et calibration	séparer exploitation et exploration ; représenter utilisateur à plusieurs horizons. [32]
TikTok	watch time, completion, like, favorite, share, comment, follow, search, sons, heure, longueur, local	ranking prédictif personnalisé	intérêts initiaux puis apprentissage comportemental	récence, diversité, évitement de répétitions, vérification renforcée du contenu qui monte	les signaux implicites et négatifs doivent peser autant que le follower count. [21]
SoundCloud	proximité audio, historique d'écoute, likes, follows, reposts, activité	audio similarity + graph/social + feed personnalisé	First Fans expose un nouvel upload à environ 100 auditeurs compatibles	ciblage d'auditeurs réels, limitation du volume d'uploads éligibles, fan activity	excellente référence pour l'axe `emergence`. [9]
YouTube	clics, watch time, likes/dislikes, shares et autres signaux de satisfaction	génération de candidats puis ranker séparé	contenu nouvellement uploadé traité par mécanismes de retrieval/content	systèmes de qualité/safety et réduction des contenus problématiques	architecture multi-stage éprouvée ; ne pas faire scorer tout le catalogue par le modèle lourd. [33]

Système	Signaux publiquement documentés	Architecture / mécanisme	Cold-start et exploration	Diversité, sécurité, anti-gaming	Leçon pour Kinda
Reddit	up/downvotes, communauté, commentaires, type, âge/flair du post, historique et communautés utilisateur	feed Best personnalisé + tris Hot/ Top/New	plus de recommandations lorsque compte/ souscriptions apportent peu d'information	« show fewer », mute, désactivation des recommandations ; Hot privilégie les posts récents recevant des votes	bon modèle conceptuel pour combiner communauté + âge + engagement, mais trop simple seul pour la musique. [34]

Spotify : du collaborative filtering à la représentation multimodale. Les travaux Spotify sur les représentations séquentielles montrent que l'ordre récent des consommations et le contexte de session apportent un signal utile au-delà d'un simple profil statique. [35] La génération 2025 va plus loin en fusionnant audio, co-occurrence collaborative, horizons temporels et onboarding dans une représentation générale réutilisable pour retrieval, ranking et search. [23]

Le principal enseignement est que Kinda ne doit pas choisir entre « collaboratif » et « content-based ». **Le bon système est hybride.**

SoundCloud est probablement le benchmark le plus directement comparable à la problématique émergence. Sa fonction Amplify/First Fans recommande un nouvel upload à environ 100 auditeurs dont le profil correspond au son, en utilisant historique et activité, précisément pour résoudre le problème des zéro plays. [36] Sa logique de related tracks repose de plus sur un graphe de relations et d'interactions. [24]

Une transposition Kinda serait de réserver, par exemple, **10 % des impressions Discovery** à des contenus dont l'artiste est nouveau pour l'audience mais qui dépassent un seuil de qualité, puis de mesurer leur conversion avant d'élargir l'exposition.

TikTok montre pourquoi les métriques de durée et de feedback négatif sont essentielles. Sa documentation 2025 cite likes, partages, favoris, commentaires, temps de visionnage, complétion, follows, recherches et comportements d'utilisateurs similaires. Elle précise également que récence, caractère local, longueur et son utilisé interviennent, avec des mécanismes empêchant des suites trop répétitives. [21]

Le follower count ne doit donc jamais être un signal dominant. Il produit un effet « riche devient plus riche » et peut être acheté ou manipulé.

Reddit rappelle la valeur d'un score explicitement temporel. La documentation actuelle présente `Hot` comme un tri mettant en avant les contenus récents recevant des upvotes, tandis que `Best` personnalise à partir de l'activité utilisateur, des communautés et de nombreuses caractéristiques du post. [37] Pour l'actualité électronique, cette idée doit toutefois être raffinée avec des demi-vies par type de contenu : un décès, un line-up et une interview longue ne vieillissent pas au même rythme.

La diversité ne doit pas être considérée comme une conséquence automatique de la personnalisation. Les travaux Spotify ont étudié explicitement les effets algorithmiques sur la diversité de consommation, ce qui montre que pertinence immédiate et diversité ne sont pas un seul objectif. [38] Il est préférable de maximiser la pertinence au ranker, puis de gérer artistes, genres, sources et nouveauté dans un reranker contrôlable.

Le multimodal aide particulièrement au cold-start. Les travaux ISMIR sur la recherche artiste cross-modale montrent l'intérêt de combiner représentations musicales et autres modalités, notamment pour améliorer couverture et récupération des artistes moins populaires. [39] Cela correspond exactement au cas de Kinda : lorsqu'un artiste émergent n'a presque pas d'historique d'engagement, l'audio, le label, la description, les artistes voisins et les bookings peuvent le situer.

Comparaison des familles d'algorithmes envisagées pour Kinda :

Approche	Forces	Faiblesses	Cold-start	Coût / complexité	Rôle recommandé
Règles + score pondéré	explicable, très rapide	interactions non linéaires limitées	bon si metadata disponible	très faible	baseline et garde-fous
LLM editorial scorer	excellent contexte sémantique, flexible	coût, variance, calibration	bon texte	moyen/ élevé	`relevance`, catégories, extraction
Logistic regression	calibrable, interprétable	interactions limitées	moyen	faible	baseline ML
LightGBM / LambdaMART	très performant sur données tabulaires, non linéaire	dépend du feature engineering	bon	faible/ moyen	**premier ranker recommandé**
Collaborative filtering	découvre goûts latents	faible sur nouveaux utilisateurs/ items	mauvais seul	faible/ moyen	composante affinité
Content-based embeddings	bon nouveaux items	risque de sur-similarité	excellent item	moyen	texte/audio
Two-tower retrieval	scalable millions d'items	demande interactions	moyen avec multimodal	moyen/ élevé	phase de croissance
Graph embeddings / GNN	exploite relations artistes/labels/ users	complexité et propagation des biais	assez bon	élevé	signaux de scène

Approche	Forces	Faiblesses	Cold-start	Coût / complexité	Rôle recommandé
Contextual bandit	exploration adaptative	risque produit, évaluation complexe	très bon	élevé	Discovery à maturité
LLM end-to-end ranking	riche sémantiquement	coût, latence, instabilité, difficile à auditer	bon	très élevé	seulement reranking ponctuel

Pour le volume actuel de Kinda, **LightGBM + embeddings + règles** offre vraisemblablement le meilleur rapport valeur/complexité. Les modèles deep de retrieval deviendront utiles avec un catalogue et surtout un volume d'interactions bien supérieurs.

Algorithme optimisé proposé pour Kinda

Le document de production Kinda montre un système déjà pensé avec soin : ingestion puis déduplication, élection du meilleur représentant, scoring, illustration uniquement au-dessus d'un seuil, stockage des artistes, purge ; trois notes indépendantes ; seuil de publication à 60 ; préfiltre local à 45 ; exceptions multi-sources et artistes suivis ; garde-fou Instagram quasi vide ; sortie structurée et commits par article. filecite turn0file0

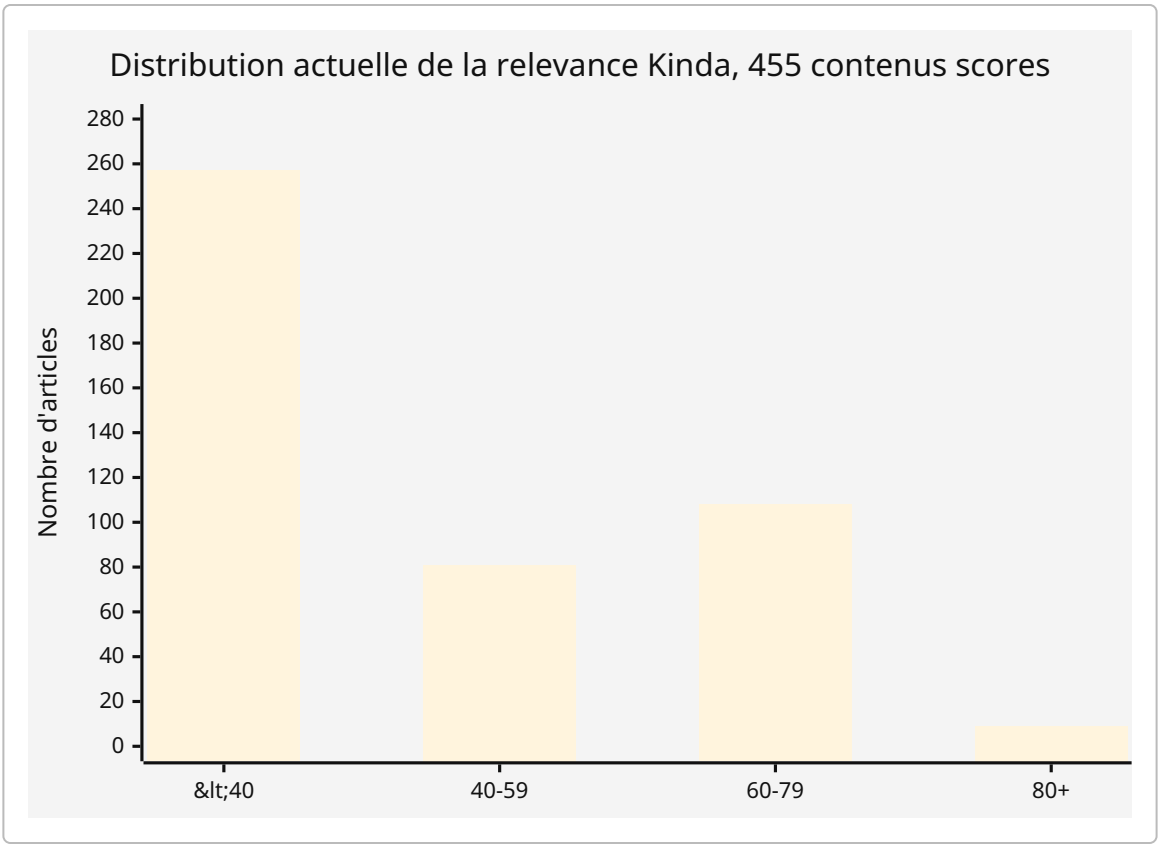
Cette architecture doit être étendue, pas remplacée.

Le diagnostic principal est le suivant :

Élément actuel	Diagnostic	Décision recommandée
`relevance`, `emergence`, `hotness` séparés	excellente propriété	**conserver absolument**
Dédup avant scoring	très bon coût/qualité	conserver et enrichir en clustering événement
Préfiltre Qwen local	logique fail-open saine	recalibrer sur dataset beaucoup plus grand
Claude/LLM comme juge éditorial	fort pour la sémantique	conserver comme feature / teacher, pas unique ranker
Seuil publication 60	règle éditoriale claire	conserver comme gate initiale et calibrer périodiquement
Cluster $\geq$3 force LLM	bon signal d'importance	convertir aussi en feature continue de burst

Élément actuel	Diagnostic	Décision recommandée
Artiste suivi force LLM	bonne protection A&R	conserver
Post <6 mots plafonné 29	garde-fou utile	conserver mais rendre multimodal pour UGC live
38–41 % environ en `other`	taxonomie probablement insuffisante	passer catégorie + facettes multi-label
`ecology=0`	classe rare ou consigne trop stricte	revue d'échantillons + classe/facette séparée
aucune `emergence≥80`	possible calibration trop conservatrice	établir ground truth A&R et courbe de calibration
~7 % d'appels évités par le local	bénéfice coût limité à ce stade	optimiser seuil sous contrainte de recall

Les chiffres ci-dessus proviennent de la base de production décrite dans le document Kinda au 23 septembre 2026. filecite turn0file0



Le changement conceptuel : quatre sorties plutôt qu'une fusion.

Le modèle doit produire :

$$\{Relevance,\ Emergence,\ Hotness,\ RankScore_u\}$$

`Relevance`, `Emergence` et `Hotness` restent globales et indépendantes. `RankScore_u` est personnalisé et ne peut intervenir **qu'après** les règles d'éligibilité.

Par défaut :

$$Eligible_{main} = (Relevance \geq 60) \wedge Safety \wedge Quality$$

$$Eligible_{A\&R} = (Emergence \geq 55) \wedge Safety$$

$$Eligible_{alert} = (Hotness \geq 80) \wedge (Relevance \geq 60) \wedge (Confidence \geq 0.75)$$

Ainsi, un EP inconnu à `relevance=25`, `emergence=75` n'envahit pas le flux d'actualité mais entre bien dans Discovery/A&R, ce qui est exactement la motivation originelle des trois axes Kinda.
filecite turn0file0

Features candidates.

Famille	Features recommandées	Traitement
Éditorial	score LLM, catégorie, confiance, fait/date/chiffre détectés, information density	calibration supervisée
Texte	embeddings titre/résumé/caption, entités, sentiment factuel, langue	encoder multilingue
Audio	BPM, key/mode, énergie, loudness, timbre, spectral/onset descriptors, embedding musical	normalisation par genre
Genre	probabilités multi-label : techno, house, D&B, ambient, etc.	taxonomie hiérarchique
Artiste	taille, trajectoire, âge du projet, releases, accélération mentions	log + dérivées temporelles
Source	type, historique précision, original/repost, expertise thématique	réputation bayésienne
Engagement	impressions, dwell, completion, saves, shares, comments, follows, hides	exposure-normalized
Vélocité	actions/minute, EWMA, accélération, anomalie par âge du post	z-score par cohortes
Graphe	user↔artist, artist↔label, artist↔venue, repost/co-mention, curator↔scene	embeddings / PPR
Événement	festival, club, ville, date, lineup, annonce officielle	entités structurées
Local	France, région, ville, distance, scène locale	score continu

Famille	Features recommandées	Traitement
Fraîcheur	âge + demi-vie par catégorie	exponentielle
Nouveauté	distance du contenu récemment exposé	embedding similarity
Emergence	nouveauté artiste, momentum, support crédible, bookings	modèle dédié
Abuse	burst suspect, comptes corrélés, duplication, engagement improbable	pénalité + review
Contexte user	historique long/moyen/court, heure, device/surface	modèle personnalisé

La dimension audio ne doit pas se limiter à BPM/key. Pour un produit électronique, le BPM est utile, mais un chiffre seul confond aisément halftime/double-time et ne capture ni timbre, ni groove, ni esthétique. Les embeddings audio auto-supervisés ou contrastifs fournissent une représentation beaucoup plus riche ; les recherches cross-modales récentes montrent leur utilité pour la récupération musicale, notamment lorsque les artistes sont moins populaires. [39] Le MTG-Jamendo Dataset fournit par exemple plus de 55 000 titres complets annotés par genres, instruments et mood/themes, avec des features audio pré-calculées ; il constitue un bon benchmark de prototypage, sous réserve de respecter ses restrictions de licence pour les usages commerciaux. [40]

Score de ranking initial.

Toutes les composantes suivantes sont ramenées dans `[0,1]` :

$$B(u,p,t) = 0.22P + 0.20E + 0.12V + 0.10Q + 0.09F + 0.08G + 0.07A + 0.05N + 0.04L + 0.03X$$

avec :

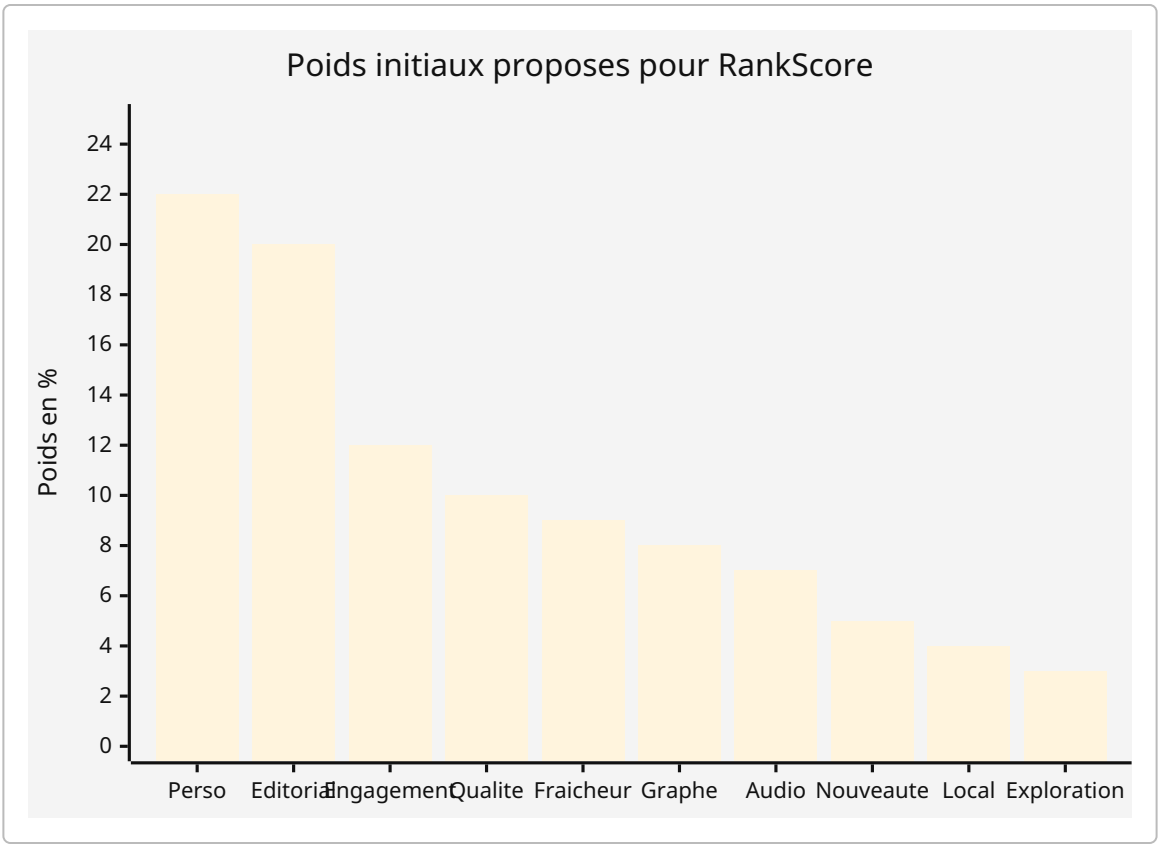
`P` = personnalisation utilisateur/post
`E` = relevance éditoriale calibrée
`V` = engagement velocity corrigée de l'exposition
`Q` = qualité / densité informative / factualité
`F` = fraîcheur
`G` = graphe social et de scène
`A` = affinité audio/content
`N` = nouveauté
`L` = localité pertinente
`X` = exploration contrôlée.

Puis :

$$Score = 100C \cdot clip(B - 0.35R, 0, 1)$$

où `R∈[0,1]` représente le risque d'abus et `C∈{0,1}` l'éligibilité.

Ces poids ne sont pas des « feature importances mesurées ». Ils sont une **initialisation experte** destinée au premier A/B test.



Pour un utilisateur anonyme, les 22 points de personnalisation peuvent initialement être redistribués :

$$E : +8, \quad V : +5, \quad F : +4, \quad G : +3, \quad N : +2$$

ce qui crée un bon feed global sans prétendre connaître l'utilisateur.

Personnalisation hybride.

Je recommande :

$$P = 0.45P_{collab} + 0.25P_{content/audio} + 0.15P_{graph} + 0.15P_{session}$$

`P_collab` capture « les personnes ayant des goûts similaires ont aimé cela ».
`P_content/audio` capture proximité sonore, genre, artiste, événements et texte.
`P_graph` utilise follows, curateurs, scènes et relations.
`P_session` réagit aux dernières minutes/heures.

Au cold-start utilisateur :

$$P_{cold} = 0.40Onboarding + 0.30ContentAffinity + 0.20Local + 0.10PopularDiverse$$

Spotify publie précisément une approche où onboarding, audio et collaboratif sont complémentaires pour les nouveaux utilisateurs, et où les embeddings passent progressivement des signaux d'onboarding au comportement observé. [23]

Fraîcheur.

Une décroissance exponentielle simple est plus contrôlable qu'un bonus « récent » opaque :

$$F(p,t) = e^{-\ln(2)\cdot AgeHours/H_{category}}$$

Valeurs de départ :

Type	Demi-vie proposée
décès / breaking drama	3 h
surprise announcement	6 h
UGC d'un live de la veille	12 h
event / festival announcement	18 h
sortie musicale	36 h
industry / gear	36–48 h
culture / interview / écologie	48 h

Le système actuel purge la plupart des articles de plus de deux jours ; une demi-vie supérieure à 48 h aurait donc peu d'effet dans le feed actuel, même si l'historique A&R doit continuer d'être conservé séparément. filecite turn0file0

Engagement corrigé.

Ne jamais utiliser :

$$likes + 2 \times comments + 3 \times shares$$

sur des valeurs brutes. Ce système favorise mécaniquement les grands comptes et les contenus déjà exposés.

Une première utility peut être :

$$ActionValue = 1\,Like + 2\,QualifiedComment + 3\,Share + 4\,Save + 4\,ArtistFollow - 5\,Hide - 8\,Report$$

puis :

$$RawRate = \frac{ActionValue}{Impressions + \epsilon}$$

et enfin normaliser le résultat dans une cohorte :

`{format × age_bucket × source_size × genre}`.

Pour les petits volumes, appliquer un shrinkage bayésien :

$$SmoothedRate = \frac{Positive + \alpha}{Impressions + \alpha + \beta}$$

avec, pour démarrer, `α=1, β=20`, puis apprendre ces priors par cohortes.

La vélocité doit être calculée sur plusieurs fenêtres :

$$V = 0.50z(v_{15m}) + 0.30z(v_{1h}) + 0.20z(v_{6h})$$

et non par « nombre total de likes ». Cette caractéristique répond beaucoup mieux à la question « est-ce que cela est en train de monter ? ».

Hotness améliorée.

Aujourd'hui, `hotness` est principalement un jugement sémantique LLM. filecite turn0file0 Elle devrait devenir hybride :

$$H = 100 \cdot clip(0.30B_s + 0.25V + 0.20C_b + 0.15F + 0.10S_a - 0.25R,\ 0,\ 1)$$

où `B_s` = breaking-news semantic probability, `V` = engagement velocity, `C_b` = burst multi-sources, `F` = freshness, `S_a` = autorité de la source relativement au fait.

La notification n'est déclenchée que si :

$$H \geq 80 \wedge Relevance \geq 60 \wedge confidence \geq 0.75$$

Cela rend l'alerte plus résistante à un contenu viral mais hors ligne éditoriale.

Emergence améliorée.

$$Em = 100 \cdot clip(0.25N_a + 0.20M_a + 0.15C_s + 0.15CrossSource + 0.10L + 0.10Booking + 0.05A_d,\ 0,\ 1)$$

où :

`N_a` = nouveauté / faible establishment de l'artiste,
`M_a` = accélération corrigée de sa taille initiale,
`C_s` = soutien de curateurs/DJs/labels crédibles,
`CrossSource` = confirmations indépendantes,
`L` = intérêt local français,
`Booking` = validation club/festival,
`A_d` = distinctivité/proximité audio.

C'est sur cet axe que la logique SoundCloud First Fans et l'exploration Spotify sont les plus transposables : l'absence d'historique doit provoquer une **exploration mesurée**, pas une invisibilité. [41]

Taxonomie. La catégorie unique actuelle doit rester utile au design éditorial, mais le modèle devrait en parallèle produire des facettes :

```
primary_category = event_festival

facets:
  genres      = [techno, hard_techno]
  artists     = [...]
  geography   = [France, Bretagne, Brest]
  format      = [ugc_live]
  subjects    = [festival, lineup]
  mood        = [high_energy]
  lifecycle   = [announcement]
  scene       = [underground]
```

Cela réduira naturellement le fourre-tout `other`, sans nécessiter 50 catégories mutuellement exclusives.

Reranking diversité et sérendipité.

Après le ranker, appliquer :

$$p^* = \arg\max_p \left[\lambda \frac{Score(p)}{100} - (1-\lambda) \max_{j \in L} sim(p,j) + \eta NovelArtist + \gamma UnderexposedGenre - \kappa SameCreator \right]$$

Valeurs initiales :

`λ = 0,78`
`η = 0,06`
`γ = 0,04`
`κ = 0,08`.

Dans un top 10, des contraintes initiales raisonnables seraient : maximum deux contenus du même artiste, maximum deux contenus de la même source, et au moins un slot « exploration » lorsqu'un candidat émergent dépasse son seuil qualité. Les quotas de genres doivent rester **conditionnels à la qualité du candidate pool**, sinon la diversité devient artificielle.

Les travaux Spotify montrent que recommandation locale et exploration de nouveaux créateurs peuvent produire des gains d'engagement mesurables ; il existe donc des raisons empiriques de réserver de l'exposition à la nouveauté plutôt que de laisser les grands artistes gagner toutes les enchères implicites. [42]

Préfiltre Kinda.

L'expérience interne de 36 articles d'août 2026, où Qwen n'a pas enterré de contenu que Haiku conservait au-dessus de 60, est encourageante mais trop petite pour fixer définitivement un seuil.
filecite turn0file0 Le bon critère de tuning n'est pas « précision du petit modèle », mais :

$$\max CostSaving \quad sous \quad Recall_{valuable} \geq 99\%$$

où `valuable` inclut :

$$Relevance \geq 60 \vee Emergence \geq 55 \vee Hotness \geq 80$$

La règle de routage recommandée devient :

$$CallHeavy = (r_l \geq T_r) \vee (e_l \geq T_e) \vee (h_l \geq T_h) \vee cluster \geq 3 \vee trackedArtist \vee uncertainty \geq U$$

avec les seuils actuels conservés initialement puis recalibrés sur au moins plusieurs centaines à quelques milliers de cas annotés. Le principe fail-open existant doit rester inchangé. filecite turn0file0

Explicabilité. Chaque recommandation devrait pouvoir générer trois motifs structurés, issus des features réelles, par exemple :

> Recommandé car vous suivez cet artiste, cette sortie est proche de votre historique techno et elle est reprise par trois sources indépendantes.

ou :

> Découverte : artiste français émergent, première programmation dans un club suivi, forte accélération depuis six heures.

Il faut éviter les explications génératives non ancrées. L'explication doit être construite à partir des top contributions du modèle, idéalement avec SHAP côté analyse et templates côté produit.

Évaluation, sûreté, équité et confidentialité

Un recommender ne doit pas être évalué uniquement sur « est-ce que le score prédit le clic ? ». Kinda doit mesurer quatre choses indépendamment : **qualité du ranking, découverte, santé du catalogue et sûreté**.

Métriques offline.

Pour des labels binaires :

$$Precision@k = \frac{\#\text{items pertinents dans top k}}{k}$$

Pour un jugement gradué `0–3` ou `0–4`, NDCG est préférable :

$$DCG@k = \sum_{i=1}^{k} \frac{2^{rel_i} - 1}{\log_2(i+1)}$$

$$NDCG@k = \frac{DCG@k}{IDCG@k}$$

MAP est utile lorsqu'il existe plusieurs résultats pertinents par requête/utilisateur :

$$MAP = \frac{1}{|U|} \sum_{u} AveragePrecision(u)$$

Le dashboard offline devrait contenir au minimum :

Domaine	Métriques
Retrieval	Recall@50, Recall@200
Ranking	NDCG@10, NDCG@20, Precision@5/10, MAP
Calibration	Brier score, ECE, calibration curves
Freshness	âge médian top-k, recall breaking-news
Discovery	new-artist recall, long-tail exposure
Diversité	intra-list diversity, genre/source/artist entropy
Couverture	catalog coverage, % artistes obtenant une impression qualifiée
Équité	exposition par bucket popularité, géographie, indépendant/major
Sûreté	spam precision/recall, abuse leakage
Système	p50/p95/p99 latency, error rate, cache hit

Pour un candidat stage, **Recall@N** est plus important que NDCG : le ranker ne pourra jamais récupérer un contenu absent de ses candidats.

Ground truth Kinda.

Le dataset propriétaire devrait devenir l'actif central. Chaque contenu reçoit indépendamment :

`relevance ∈ {0,1,2,3,4}`
`emergence ∈ {0,1,2,3,4}`
`hotness ∈ {0,1,2,3,4}`
`informativeness ∈ {0,1,2}`
`genre[]`
`geography[]`
`abuse/spam`
`confidence`.

Au moins 20 % des contenus devraient être annotés par deux personnes, les désaccords les plus forts faisant l'objet d'une adjudication. Les exemples proches des seuils 40/60/80 doivent être sur-échantillonnés, car ce sont eux qui ont la plus forte valeur d'apprentissage.

Il faut également créer des **hard negatives** : post d'une superstar sans information, teaser vide, repost tardif d'un événement connu, contenu électronique mais hors actualité, fake engagement, ligne-up quasi identique, même communiqué réécrit par plusieurs médias.

C'est précisément là que l'actuel système Kinda a rencontré des erreurs réelles — légendes telles que `[camera]`, « I-VIEW » ou « feat. » notées trop haut — et qui ont motivé le garde-fou des six mots significatifs. 🟥filecite🟥turn0file0🟥

Datasets externes. Les données externes servent à pré-entraîner ou benchmarker les représentations audio, pas à substituer les labels métier Kinda. MTG-Jamendo fournit plus de 55 000 pistes avec tags de genre, instruments et thèmes et constitue une base utile pour l'auto-tagging. [40] Des datasets comparatifs comme MusAV fournissent également des annotations d'arousal/valence, utiles à titre expérimental pour les dimensions énergétiques. [43]

A/B testing.

L'unité de randomisation devrait être l'utilisateur, et non la requête ou l'impression, pour éviter qu'un même utilisateur alterne entre deux philosophies de feed.

Une première suite de tests pourrait être :

Test	Control	Treatment	KPI primaire	Guardrails
Ranker ML	score éditorial actuel	hybrid RankScore	qualified engagement / impression	hide, report, latency
Fraîcheur	ranking actuel	demi-vies catégorie	discovery des actus <6 h	perte culture/ long-form
Diversité	classement pur	MMR rerank	discovery rate	NDCG, satisfaction
Emerging slot	aucun slot garanti	1/10 conditionnel	follow/save new artist	skip/hide
Audio	pas d'audio	embeddings+BPM/ etc.	discovery completion	latency
Local	bonus Bretagne fixe	local affinity continue	engagement local	concentration
Explore	exploitation pure	bandit 10 %	new-item success	satisfaction globale

Un KPI de référence pour Kinda pourrait être :

$$QualifiedDiscoveryRate = \frac{4Save + 4Follow + 3Share + 2DeepRead + 2OutboundListen}{Impressions}$$

avec coefficients à apprendre plutôt qu'à graver définitivement.

Les métriques secondaires doivent inclure retour à J+7/J+30, découverte d'artistes inconnus, taux de masquage, répétition d'un même artiste, concentration par source, profondeur de session et clics vers événement/streaming.

La puissance statistique doit être calculée avant test. Pour une métrique approximativement continue :

$$n \approx \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2}{\delta^2}$$

où `δ` est le minimum detectable effect réellement utile au produit. Il ne faut donc pas décréter arbitrairement qu'un test dure « une semaine » ; il doit couvrir au minimum les principaux cycles jour/semaine et atteindre la puissance prévue.

Biais d'exposition. Les données historiques d'un recommender sont biaisées par le recommender précédent : un contenu jamais montré ne peut pas avoir obtenu de clic. Il faut donc journaliser `candidate_set`, `rank`, `score`, `probability/propensity`, `impression`, puis utiliser lorsque pertinent des évaluations IPS / doubly robust ou des expériences exploratoires randomisées.

Tests anti-abus.

La suite de tests doit explicitement simuler :

Attaque	Signal attendu
achat soudain de likes	velocity anormale mais faible diversité des comptes
bot farm	profils corrélés, faible historique authentique
follow/unfollow artificiel	graph churn
100 reposts quasi identiques	near-duplicate cluster
hashtags trompeurs	incompatibilité texte/audio/entities
faux événement	absence de confirmation source primaire
promo artiste inconnue répétée	duplicate/promotional pattern
génération IA industrielle	volume anormal + faible diversité + duplication audio
manipulation par gros compte	engagement corrigé de l'exposition
brigading coordonné	burst graph + comptes co-actifs

L’objectif n’est pas de détecter « ce qui est populaire » mais **ce qui est statistiquement incompatible avec une popularité organique**.

Équité. La fairness la plus pertinente pour Kinda est d’abord une fairness d’**opportunité d’exposition** : artistes nouveaux vs établis, grandes vs petites sources, Paris vs régions, France vs international, gros labels vs indépendants. Les travaux en ranking montrent que des contraintes de fairness peuvent être incorporées dans l’objectif ou le reranking plutôt que d’être laissées au hasard. 44

Il ne faut pas inférer automatiquement des données sensibles telles que genre, origine ethnique ou orientation à partir de noms/photos afin de construire des quotas. Les dimensions protégées ne doivent être utilisées à des fins de mesure qu’avec une base juridique, une qualité de données et une gouvernance appropriées.

Confidentialité et réglementation. Pour des utilisateurs européens, le RGPD impose notamment licéité/transparence, limitation de finalité, minimisation et limitation de conservation des données personnelles. 45 En pratique, Kinda devrait :

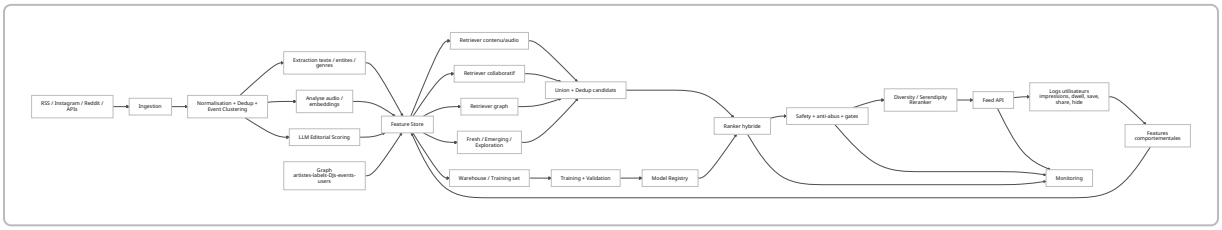
conserver l’historique granulaire seulement aussi longtemps que nécessaire ; produire ensuite des agrégats/embeddings ; séparer identifiants et données comportementales ; permettre la suppression du profil ; utiliser la géographie la moins précise nécessaire ; ne pas collecter de caractéristiques sensibles pour améliorer marginalement le ranking ; et documenter clairement à quoi sert la personnalisation.

Le DSA impose en outre aux **très grandes plateformes** au moins une option de recommandation ne reposant pas sur le profilage. Même si Kinda n’atteint pas nécessairement ce statut juridique, proposer dès le départ un feed « éditorial/non personnalisé » est un excellent principe produit et de confiance. 46

Un contrôle de type « plus de techno / moins de festivals / plus local / moins de pop » serait également cohérent avec l’évolution récente de grands produits : Instagram a commencé en 2026 à exposer et rendre modifiables les thèmes qu’il pense pertinents pour le feed Reels. 47

Architecture, feuille de route et plan d’action

L’architecture cible doit rester **logiquement sophistiquée mais physiquement simple tant que le volume l’autorise**.



À l’échelle actuelle, cette architecture peut être implémentée sans Kafka ni cluster de feature store distribué :

Fonction	Phase actuelle recommandée	À grande échelle
Ingestion	workers existants + queue	Kafka / PubSub
Base opérationnelle	PostgreSQL	PostgreSQL + data services
Analytics	Postgres/object store + DuckDB/ warehouse	BigQuery/Snowflake/Databricks
Vectors	pgvector/HNSW	FAISS/Voyager/service ANN
Online features	Redis	Feast/custom feature platform
Feature pipelines	jobs Python	Spark/Flink
Ranker	LightGBM/LambdaMART	multi-task DNN
Retrieval	règles + vector search	two-tower ANN
Graph	features SQL/NetworkX batch	graph store/GNN
Model registry	MLflow ou équivalent	idem
Serving	FastAPI/service existant	Kubernetes autoscaling
Observability	OpenTelemetry + Prometheus/Grafana	idem à plus grande échelle
Experiments	flags + logs	plateforme d'expérimentation dédiée

Le pattern batch + quasi temps réel est cohérent avec ce que Spotify documente pour ses représentations utilisateurs : batch pour la couverture, mise à jour rapide après activité utilisateur pour réagir aux nouvelles intentions. [23]

Cadence recommandée.

Les features de fraîcheur et engagement doivent être actualisées en secondes/minutes. Les embeddings item sont calculés une fois à l'ingestion puis lorsque le contenu change. Les profils session sont temps réel ou quasi temps réel. Les modèles de ranking peuvent être réentraînés quotidiennement au début, puis selon la dérive réellement observée. Les embeddings de graphe ou représentations longues peuvent être hebdomadaires.

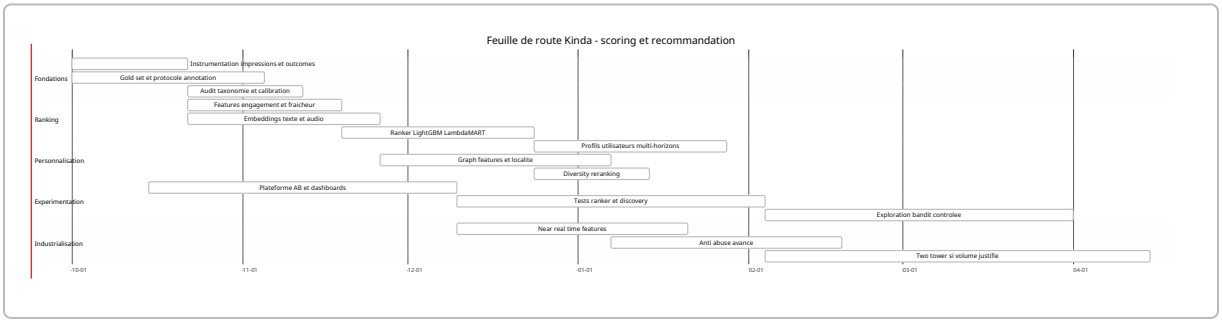
Le monitoring doit comparer en permanence :

`distribution actuelle vs training`,
`calibration`,
`genre/source exposure`,
`score par modèle/version`,
`empty-post leakage`,
`false-negative émergence`,
`latency`,

`duplicate rate`,
`abuse rate`,
`fraction exploration`,
`fraction other`.

Pour le LLM, conserver un **golden set fixe** de plusieurs centaines de cas difficiles et le réexécuter à chaque changement de prompt ou de modèle. Le document Kinda montre précisément pourquoi : des changements éditoriaux antérieurs ont eu des effets inattendus, comme la décote des médias qui avait enterré une actualité Fred again.. liée à GTA VI. filecite turn0file0

Feuille de route proposée :



Il s'agit d'un calendrier d'ingénierie indicatif, pas d'une prévision contractuelle.

Plan d'action priorisé. Les efforts ci-dessous sont des estimations de planification en personnes-semaines d'ingénierie/data, hors délais calendaires de collecte d'interactions. « Impact » désigne le levier attendu, pas un uplift garanti.

Priorité	Action	Pourquoi	Effort estimé	Impact attendu
P0	Loguer impression, rank, candidate set, dwell, save/ share/hide	sans exposition, l'engagement est inutilisable causalement	2–3 pers.-sem.	**critique**
P0	Construire gold set 1 000–3 000 cas	calibration des seuils et mesure des régressions	3–6 + annotation	**critique**
P0	Auditer `other` et `ecology`	`other` domine et ecology est vide	1–2	**très élevé**
P0	Calibrer les trois axes indépendamment	aucune emergence ≥80 suggère un problème à tester	2–3	**très élevé**
P0	Normaliser engagement par exposition/âge	élimine avantage mécanique des gros comptes	2–4	**très élevé**

Priorité	Action	Pourquoi	Effort estimé	Impact attendu
P0	Revalider le préfiltre sur dataset beaucoup plus large	36 cas insuffisants pour un seuil critique	1–2	élevé / coût
P1	Ajouter facettes genres/ géo/format	base du retrieval et de l'explicabilité	2–4	**très élevé**
P1	Embeddings texte	similarité, clustering et cold-start	1–2	élevé
P1	Embeddings + features audio	différenciation électronique forte	3–5	**élevé**
P1	LightGBM/LambdaMART ranker	apprend interactions sans stack deep lourde	3–5	**très élevé**
P1	Fraîcheur par demi-vie catégorie	améliore breaking vs evergreen	1–2	élevé
P1	MMR / contraintes diversité	empêche répétition artiste/source/genre	1–2	élevé
P1	Feed A&R / Emerging distinct	exploite enfin réellement `emergence`	2–3	**très élevé**
P1	Explications basées sur features	confiance éditoriale/ utilisateur	1–2	moyen/élevé
P2	Graphe artiste-label-DJ-event-user	signaux de scène et influence qualitative	4–7	élevé
P2	Exploration contrôlée nouveaux artistes	résout cold-start émergence	3–5	**très élevé** si trafic suffisant
P2	Détection de manipulation graphe/bursts	protège le ranker d'engagement	3–6	élevé
P2	Profiles multi-horizons/ session	personnalisation fine	4–6	élevé
P3	Two-tower retrieval	nécessaire lorsque catalogue/interactions grossissent	6–10	variable aujourd'hui
P3	Contextual bandit	allocation adaptative exploration	6–10	élevé à maturité
P3	GNN	capture relations complexes de scène	8–12	incertain avant volume

Priorité	Action	Pourquoi	Effort estimé	Impact attendu
P3	Streaming feature platform complète	forte scalabilité	8–16	faible à court terme

Ordre d'exécution recommandé. Le plus gros retour sur investissement immédiat ne vient ni d'un GNN ni d'un LLM plus gros. Il vient de la création de données fiables. L'instrumentation doit précéder le nouveau modèle ; le gold set doit précéder le tuning du préfiltre ; la normalisation d'engagement doit précéder l'utilisation de la popularité ; le ranker tabulaire doit précéder le deep learning.

À l'issue de la première phase, Kinda devrait disposer de cinq contrats stables :

1. les trois scores éditoriaux ne se compensent jamais ;
2. un score personnalisé ne franchit jamais seul une porte éditoriale ;
3. toute exposition est loguée avant d'utiliser l'engagement ;
4. tout modèle possède une version, une calibration et un golden set ;
5. une partie contrôlée de l'exposition est réservée à apprendre ce que l'on ne sait pas encore.

Cette dernière propriété est probablement la plus stratégique pour une application consacrée à la musique électronique. Spotify décrit explicitement l'exploration comme un moyen de résoudre le cold-start des créateurs émergents ; SoundCloud expose volontairement de nouveaux titres à une première audience sonorement compatible. [48] Un produit qui ne fait qu'exploiter les signaux passés est mécaniquement excellent pour recommander les artistes déjà connus et médiocre pour identifier la prochaine scène.

Pour Kinda, le différenciateur défendable n'est donc pas simplement « mieux classer les actualités électroniques ». Il est de construire un **graphe temporel des scènes électroniques françaises et internationales**, dans lequel actualités, artistes, sons, labels, lieux, événements, DJs, curateurs et comportements utilisateurs se renforcent mutuellement. La mémoire `artist_mentions` déjà conservée au-delà de la purge des articles constitue le premier embryon de cet actif. filecite turn0file0

À terme, la proposition de valeur algorithmique devient plus riche qu'un feed :

$$\text{détecter tôt} \rightarrow \text{comprendre pourquoi} \rightarrow \text{trouver l'audience pertinente} \rightarrow \text{mesurer la confirmation}$$

Le marché actuel favorise exactement cette architecture : la découverte se déplace entre réseaux sociaux, streaming, communautés et live ; l'électronique progresse fortement dans les environnements de découverte numérique ; les plateformes elles-mêmes investissent dans le cold-start, la personnalisation multimodale et la recommandation communautaire. [49]

La meilleure optimisation de Kinda est donc **multi-objectifs, hybride, temporelle et explicitement exploratoire** : garder l'intelligence éditoriale actuelle comme garde-fou et source de features, lui ajouter le comportement sans se laisser capturer par la popularité brute, utiliser l'audio et le graphe pour comprendre les scènes, puis imposer diversité et exploration après le ranking. C'est cette combinaison — davantage que n'importe quel modèle isolé — qui maximise simultanément pertinence immédiate, capacité de découverte, potentiel A&R et robustesse à long terme.

---

1 31 49 https://www.internationalmusicsummit.com/news/ims-electronic-music-business-report-2025-26
https://www.internationalmusicsummit.com/news/ims-electronic-music-business-report-2025-26

2 https://www.ifpi.org/global-music-report-2026-global-recorded-music-revenues-grow-6-4-as-record-companies-drive-innovation/
https://www.ifpi.org/global-music-report-2026-global-recorded-music-revenues-grow-6-4-as-record-companies-drive-innovation/

3 https://cnm.fr/barometre-des-usages-de-la-musique-en-france/
https://cnm.fr/barometre-des-usages-de-la-musique-en-france/

4 https://newsroom.tiktok.com/en/
https://newsroom.tiktok.com/en/

5 https://soundcloud.com/company/music-intelligence-report-2026---rising-electronic-tides
https://soundcloud.com/company/music-intelligence-report-2026---rising-electronic-tides

6 18 https://about.beatport.com/
https://about.beatport.com/

7 33 https://research.google/pubs/deep-neural-networks-for-youtube-recommendations/
https://research.google/pubs/deep-neural-networks-for-youtube-recommendations/

8 22 42 48 https://research.atspotify.com/2024/2/accelerating-creator-audience-building-through-centralized-exploration
https://research.atspotify.com/2024/2/accelerating-creator-audience-building-through-centralized-exploration

9 https://help.soundcloud.com/hc/en-us/articles/18440849363867-How-the-Feed-on-SoundCloud-Works
https://help.soundcloud.com/hc/en-us/articles/18440849363867-How-the-Feed-on-SoundCloud-Works

10 https://www.ina.fr/offres-et-services/ina-grm
https://www.ina.fr/offres-et-services/ina-grm

11 https://greenroomsupport.beatport.com/hc/en-us/articles/41043520429076-Beatport-Genres-Including-NEW-Open-Format-Genres
https://greenroomsupport.beatport.com/hc/en-us/articles/41043520429076-Beatport-Genres-Including-NEW-Open-Format-Genres

12 https://www.beatportal.com/articles/880317-beatport-launches-new-genre-ambient-experimental
https://www.beatportal.com/articles/880317-beatport-launches-new-genre-ambient-experimental

13 https://stage.research.atspotify.com/2024/5/exploring-local-musics-place-in-global-streaming
https://stage.research.atspotify.com/2024/5/exploring-local-musics-place-in-global-streaming

14 https://snepmusique.com/communiques-dossiers-de-presse/bilan-2025-snep/
https://snepmusique.com/communiques-dossiers-de-presse/bilan-2025-snep/

15 https://cnm.fr/actus/le-centre-national-de-la-musique-devoile-les-chiffres-2024-de-la-diffusion-de-spectacles-de-musique-et-de-varietes/
https://cnm.fr/actus/le-centre-national-de-la-musique-devoile-les-chiffres-2024-de-la-diffusion-de-spectacles-de-musique-et-de-varietes/

16 26 https://about.fb.com/ja/news/2025/04/instagram-reels-blend-launch/
https://about.fb.com/ja/news/2025/04/instagram-reels-blend-launch/

17 https://bandcamp.com/artists
https://bandcamp.com/artists

19 https://cnm.fr/communiques/le-centre-national-de-la-musique-publie-pour-lannee-2024-son-etude-annuelle-sur-la-diversite-musicale-en-france/
https://cnm.fr/communiques/le-centre-national-de-la-musique-publie-pour-lannee-2024-son-etude-annuelle-sur-la-diversite-musicale-en-france/

20 27 https://bandcamp.com/
https://bandcamp.com/

21 https://www.tiktok.com/safety/en/making-your-feed-for-you
https://www.tiktok.com/safety/en/making-your-feed-for-you

23 https://research.atspotify.com/2025/9/generalized-user-representations-for-large-scale-recommendations
https://research.atspotify.com/2025/9/generalized-user-representations-for-large-scale-recommendations

24 https://help.soundcloud.com/hc/en-us/articles/115003565888-Related-tracks
https://help.soundcloud.com/hc/en-us/articles/115003565888-Related-tracks

25 https://soundcloud.com/company/music-intelligence-report-2026---genre-breaking
https://soundcloud.com/company/music-intelligence-report-2026---genre-breaking

28 https://blog.bandcamp.com/2025/12/03/bandcamp-fridays-return-in-2026-with-more-opportunities-to-support-independent-music/
https://blog.bandcamp.com/2025/12/03/bandcamp-fridays-return-in-2026-with-more-opportunities-to-support-independent-music/

29 https://cnm.fr/actus/etude-sur-lia-dans-la-filiere-musicale/
https://cnm.fr/actus/etude-sur-lia-dans-la-filiere-musicale/

30 https://soundcloud.com/company/discovery
https://soundcloud.com/company/discovery

32 35 https://research.atspotify.com/2021/4/contextual-and-sequential-user-embeddings-for-music-recommendation
https://research.atspotify.com/2021/4/contextual-and-sequential-user-embeddings-for-music-recommendation

34 37 https://support.reddithelp.com/hc/en-us/articles/23511859482388-Reddit-s-Approach-to-Content-Recommendations
https://support.reddithelp.com/hc/en-us/articles/23511859482388-Reddit-s-Approach-to-Content-Recommendations

36 41 https://help.soundcloud.com/hc/pt-br/articles/16680415453979-Amplifique-faixas-para-alcan%C3%A7ar-mais-de-100-ouvintes
https://help.soundcloud.com/hc/pt-br/articles/16680415453979-Amplifique-faixas-para-alcan%C3%A7ar-mais-de-100-ouvintes

38 https://research.atspotify.com/publications/algorithmic-effects-on-the-diversity-of-consumption-on-spotify
https://research.atspotify.com/publications/algorithmic-effects-on-the-diversity-of-consumption-on-spotify

39 https://ismir2023program.ismir.net/poster_147.html
https://ismir2023program.ismir.net/poster_147.html

40 https://mtg.github.io/mtg-jamendo-dataset/
https://mtg.github.io/mtg-jamendo-dataset/

43 https://mtg.github.io/musav-dataset/
https://mtg.github.io/musav-dataset/

44 https://research.google/pubs/fairness-in-recommendation-ranking-through-pairwise-comparisons/
https://research.google/pubs/fairness-in-recommendation-ranking-through-pairwise-comparisons/

45 https://commission.europa.eu/law/law-topic/data-protection/information-business-and-organisations/principles-gdpr_en
https://commission.europa.eu/law/law-topic/data-protection/information-business-and-organisations/principles-gdpr_en

46 https://digital-strategy.ec.europa.eu/en/factpages/user-rights-under-digital-services-act
https://digital-strategy.ec.europa.eu/en/factpages/user-rights-under-digital-services-act

47 https://about.fb.com/de/news/2026/01/eine-neue-moeglichkeit-deinen-algorithmus-einzusehen-und-zu-steuern/amp/
https://about.fb.com/de/news/2026/01/eine-neue-moeglichkeit-deinen-algorithmus-einzusehen-und-zu-steuern/amp/